Relatório EP2 - Programação Concorrente e Paralela

Alunos:

- Erick Rodrigues de Santana, NUSP: 11222008
- Francisco Eugênio Wernke, NUSP: 11221870
- Thiago Guerrero Balera, NUSP: 11275297
- Vinicius Pereira Ximenes Frota, NUSP: 11221967

Professor: Alfredo Goldman

Monitores: Elisa Silva e Luciana Marques

O relatório a seguir foi elaborado com base nas instruções do EP2 da Matéria MAC0219 - Programação Concorrente e Paralela.

Objetivos

- Analisar o impacto no uso da biblioteca OpenMPI para paralelização de programas usando processos;
- Analisar a integração entre a biblioteca OpenMPI e as bibliotecas de criação de threads Pthreads e OpenMP;
- Analisar o tradeoff entre uso de threads e processos;
- Estimar os melhores parâmetros de número de processos e threads para o programa especificado;
- Comparar as diferentes versões do EP1 e do EP2.

Introdução

O principal objetivo desse exercício-programa é analisar a utilização da biblioteca OpenMPI para o cálculo do conjunto de Mandelbrot em uma região específica.

Na primeira parte vamos analisar o desempenho de uma paralização somente com processos, ou seja, utilizando somente a biblioteca OpenMPI. Em seguida, vamos analisar como uma paralização usando, em conjunto, processos e threads se comporta, utilizando também as bibliotecas de criação de thread Pthreads e OpenMP.

Nesta análise iremos estimar os melhores parâmetros dentro de uma região de interesse que será especificada mais adiante. Esses parâmetros são:

- Número de processos, para a versão usando puramente OpenMPI;
- Número de processos e threads, para as versões com a paralelização mista.

Já na segunda parte, vamos utilizar os melhores parâmetros encontrados na primeira parte e comparar o desempenho entre todas as versões do programa desenvolvidas, ou seja, todas as versões desenvolvidas nesse EP e as versões do EP1.

Metodologia

Nesta seção vamos apresentar algumas decisões de projeto.

Conjunto de Mandelbrot

Como especificado pelo enunciado, os experimentos serão feitos usando um tamanho de imagem de 4096 na região *Triple Spiral Valley*.

Regiões de interesse

Para a realização dos experimentos escolhemos as seguintes regiões de interesse para a análise:

- **Processos:** $[2^0, \ldots, 2^4]$
- **Threads:** $[2^0, \ldots, 2^5]$

A escolha dessas regiões levou em conta a capacidade computacional da rede Linux com o intuito de não monopolizar todo o poder computacional para o nosso grupo.

Escolha dos melhores parâmetros das versões do EP1

Com base no relatório do EP anterior, escolhemos 32 threads como melhor parâmetro das versões openMP e Pthreads puras.

Poder computacional

Para rodar todos os experimentos, utilizamos a máquina *Neozil* da rede Linux. Essa máquina possui 32 cores e 62.8GB de memória RAM.

Executando o programa

Para executar o programa *mandelbrot* nas versões com OpenMPI, adicionamos um argumento extra para definir o número de processos a serem criados (num_processes). Além disto, nas versões com OpenMP e Pthreads, ainda existe o argumento de quantas threads serão criadas (num_threads). Antes de executar os comandos, é necessário gerar os binários desta forma:

```
cd src
make
```

Agora, pode-se executar as três formas do *mandelbrot* com OpenMPI da seguinte forma:

```
mpirun -np <num_processes> mandelbrot_mpi
mpirun -np <num_processes> mandelbrot_mpi_omp <num_threads>
mpirun -np <num_processes> mandelbrot_mpi_pth <num_threads>
```

Já para as versões do EP1:

```
./mandelbrot_seq
./mandelbrot_omp <num_threads>
./mandelbrot_pth <num_threads>
```

Paralelização

Nesta seção iremos apresentar qual foi a estratégia de paralelização adotada.

Visão geral

Todas as versões possuem uma função chamada *mpi_managment* que é responsável por gerenciar toda a sincronização da biblioteca OpenMPI. A função é responsável por separar a imagem em blocos, definindo o valor de *i_y* para cada processo, chamar a função *compute_mandelbrot* e, por fim, sincronizar todos os dados no processo *Host*.

Sincronização dos dados

Para esta etapa, optamos por usar a função *MPI_Gather* oferecida pela biblioteca OpenMPI. Essa função reune dados de vários processos diferentes e junta todos eles em um único processo usando o *rank* de cada processo como forma de ordenação. A imagem abaixo ilustra o funcionamento dessa função:



Nossa estratégia foi reunir todos os dados de iteração de cada píxel no processo *Host*. Para isso, cada processo processa um bloco de pixels, armazenando somente o número de iterações (e não mais o código RGB) e, após o processamento, manda esses dados para o processo *Host*, que é o responsável por montar a imagem final.

Armazenar somente o número de iterações ajuda na otimização de memória e também na otimização do uso da biblioteca OpenMPI.

Estrutura do programa OpenMPI puro

Para essa versão, calculamos o valor do *chunk* de cada processo como

chunk = i_y_max/num_processes

E *i_y* como

i_y = chunk\process_rank*

Após isto, cada processo calcula todos os pixels no intervalo [i_y, i_y+chunk [

Estrutura dos programas OpenMPI+Pthreads e OpenMPI+OpenMP

Estas versões definem o *i_y* da mesma forma, entretanto, o processamento do intervalo [i_y, i_y+chunk [é separado entre as threads, implementando uma ideia similar a base e limite.

Descrição geral dos experimentos

Geração dos dados

Para a geração dos *.csv*, utilizamos alguns scripts em Bash que podem ser encontrados no nosso repositório.

Medições

Foram feitas 15 medições.

Tempo observado

O tempo coletado nos experimentos foi somente do período de processamento, ou seja, somente do período de execução da função *mpi_managment*.

Intervalo de confiança

Para 95% de nível de confiança e n-1 (14) graus de liberdade, obtemos pela tabela da t-student o valor 2.1448 para z. O código abaixo implementa uma função que retorna somente os limiares:

In [88]:

```
'''
Recebe um vetor de dados e a média desses dados.
Retorna os limiares do intervalo de confiança.
'''
def confidence_interval(vector, mean):
    z = 2.1448
    n = len(vector)
    sigma = 0
    for i in vector:
        sigma += (i - mean)**2;

    sigma /= n-1;
    sigma = sqrt(sigma);
    return z * sigma/sqrt(n);
```

Experimentos

Bibliotecas importadas:

In [89]:

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
from math import sqrt
```

Parte 1 - Estimativa dos melhores parâmetros

Sumário:

- Organização dos dados
- MPI - Visualização dos resultados
- MPI - Discussão dos resultados
- MPI Multithreads - Visualização dos resultados
- MPI Multithreads - Discussão dos resultados

O arquivo *data.csv* gerado por um dos scripts tem a estrutura apresentada abaixo.

In [90]:

```
csv = pd.read_csv("../measurements/data.csv")
print(csv)
```

```
        tipo  processos  threads         tempo
0        mpi          1        1  24237.120152
1        mpi          1        1  24395.095348
2        mpi          1        1  24355.067730
3        mpi          1        1  24333.413601
4        mpi          1        1  24350.424290
..       ...        ...      ...           ...
970  mpi_omp         16       32   1168.375492
971  mpi_omp         16       32   1420.077801
972  mpi_omp         16       32   1414.572239
973  mpi_omp         16       32   1179.508924
974  mpi_omp         16       32   1176.087618

[975 rows x 4 columns]
```

Organização dos dados

Para agrupar os dados coletados usamos a estrutura de dados de dicionário. A estrutura pode ser entendida assim:

```
{
    mpi: [
        2^0 processo: Pair<Média, Intervalo de confiança>,
        2^1 processos: Pair<Média, Intervalo de confiança>,
        ...
        2^4 processos: Pair<Média, Intervalo de confiança>
    ],
    mpi_pth: {
        2^0 thread: [
            2^0 processo: Pair<Média, Intervalo de confiança>,
            2^1 processos: Pair<Média, Intervalo de confiança>,
            2^2 processos: Pair<Média, Intervalo de confiança>,
            ...
            2^4 processos: Pair<Média, Intervalo de confiança>
        ],
        2^1 threads: [
            ...Mesmo que para 1 thread
        ],
        ...
        2^5 threads: [
            ...Mesmo que para 1 thread
        ],
    },
    mpi_omp: { ...Mesmo que mpi_pth }
}
```

Como o intervalo de confiança é simétrico em torno da média, só armazenamos os limiares.

In [91]:

```
'''
Definição das estruturas de dados
'''
data = {"mpi" : [], "mpi_pth" : dict(), "mpi_omp" : dict()}
```

Assim, podemos processar as 15 medições e armazenar a média e o intervalo de confiança nas estruturas de dados:

In [92]:

```
'''
Processamento dos dados
'''
threads = [2**i for i in range(6)]

'''
MPI Puro
'''
```

```
for i in range(5):
    vector = csv["tempo"][i*15:(i+1)*15]
    mean = sum(vector)/15
    pair = (mean, confidence_interval(vector, mean))
    data["mpi"].append(pair)

'''
MPI+Pthreads
MPI+OpenMP
'''
tipos = [ "mpi_pth", "mpi_omp"]
for tipo in tipos:
    for thread in threads:
        data[tipo][thread] = []

        filtered = csv[csv["tipo"] == tipo]
        filtered = filtered[filtered["threads"] == thread]
        filtered = list(filtered["tempo"])
        for i in range(5):
            vector = filtered[i*15:(i+1)*15]
            mean = sum(vector)/15
            pair = (mean, confidence_interval(vector, mean))
            data[tipo][thread].append(pair)
```

A função auxiliar abaixo será usada para exibir os dados nas próximas seções:

In [93]:

```
'''
Recebe os valores a serem printados.
Printa os valores numa tabela.
'''
def data_print(values):
    print ("{:^10} {:^20} {:^30}".format("Processos", "Tempo" , "Limiar do intervalo c
    for idx, value in enumerate(values):
        mean, confidence_interval = value
        print ("{:^10} {:^20} {:^30}".format(2**idx, mean, confidence_interval))
```

MPI - Visualização dos resultados

Para visualizar os resultados, plotamos um gráfico que possui o número de processos dos experimentos em função do seu tempo de processamento, em milissegundo.

Por motivos de melhor visualização dos resultados, optamos por exibir o eixo y em escala logarítimica com base 2.

In [94]:

```
'''
Definição do eixo x
'''
x = [2**i for i in range(5)]
```

In [95]:

```
'''
Coleta dos dados necessários para o plot do MPI
'''
y_mpi = [i[0] for i in data["mpi"]]
y_mpi = np.array(y_mpi)

confidence_mpi = [i[1] for i in data["mpi"]]
confidence_mpi = np.array(confidence_mpi)

'''
Plot
'''
```

```
plt.figure(figsize=(6, 4), dpi=80)
plt.fill_between(x, (y_mpi-confidence_mpi), (y_mpi+confidence_mpi), color='pink', alph
plt.scatter(x, y_mpi)

plt.grid(color='black', linewidth=0.5, axis = 'y')

plt.title("MPI")
plt.xlabel("Número de processos")
plt.ylabel("Tempo(ms)")
plt.legend(["Intervalo de confiança", "Medições"])

plt.yscale("log", base = 2)
plt.show()

'''
Print dos valores
'''
data_print(data['mpi'])
```



Processos	Tempo	Limiar do intervalo de confiança
1	24340.326674733333	74.62604191774881
2	13094.284884066667	70.34995500144774
4	6841.701110133333	82.62360100746305
8	3642.6725706666666	81.44316272438556
16	1995.2112674666666	75.7045419957342

MPI - Discussão dos resultados

Podemos notar de imediato que há uma melhora conforme aumenta o número de processos. Entretanto, é possível visualizar que a taxa de redução do tempo é cada vez menor. Uma hipótese é de que o custo de criação dos processos começa supera o ganho no uso dos mesmos.

Porém, conseguimos ver que o ganho de desempenho foi muito grande, reduzindo cerca de 22s quando comparamos a versão sequencial (1 processo) e a versão com 16 processos.

Escolhemos como melhor parâmetro o uso de 16 processos.

MPI Multithreads - Visualização dos resultados

Para visualizar os resultados, plotamos um gráfico para cada tamanho de thread comparando os diferentes números de processos em cada uma das versões.

Por motivos de melhor visualização dos resultados, optamos por exibir o eixo y em escala logarítimica com base 2.

In [96]:

```
'''
Definição do eixo x
'''
x = [2**i for i in range(5)]
```

A função abaixo recebe o número de threads e plota uma comparação entre as versões OpenMPI+Pthreads e OpenMPI+OpenMP

In [97]:

```
'''
Recebe um número de thread.
Coleta os dados para o número fornecido
e plota o gráfico de cada versão.
'''
def plot(threads):
    y = []
    confidence = []

    y_mpi_pth = [i[0] for i in data["mpi_pth"][threads]]
    y.append(np.array(y_mpi_pth))

    y_mpi_omp = [i[0] for i in data["mpi_omp"][threads]]
    y.append(np.array(y_mpi_omp))

    confidence_mpi_pth = [i[1] for i in data["mpi_pth"][threads]]
    confidence.append(np.array(confidence_mpi_pth))

    confidence_mpi_omp = [i[1] for i in data["mpi_omp"][threads]]
    confidence.append(np.array(confidence_mpi_omp))

    fig, axs = plt.subplots(1, 2, figsize = (12, 4), dpi=80)
    titles = ["MPI Pthreads", "MPI OpenMP"]
    for i, title in enumerate(titles):
        axs[i].fill_between(x, (y[i]-confidence[i]), (y[i]+confidence[i]), color='pinl
        axs[i].scatter(x, y[i])
        axs[i].grid(color='black', linewidth=0.5, axis = 'y')
        axs[i].set_yscale("log", base = 2)
        axs[i].set(ylabel = "Tempo(ms)" , xlabel = "Número de processos")
        axs[i].set_title(title)
        axs[i].legend(["Intervalo de confiança", "Medições"])
        fig.suptitle(str(threads) + " thread(s)")
    plt.show()
    '''
    Print dos valores
    '''
    print("{:^60}".format("Pthreads"))
    data_print(data['mpi_pth'][threads])
    print("\n")
    print("{:^60}".format("OpenMP"))
    data_print(data['mpi_omp'][threads])
```

Utilizando a função para os valores definidos:

In [98]:

```
for i in range(6):
    plot(2**i)
```

1 thread(s)





Pthreads

Processos	Tempo	Limiar do intervalo de confiança
1	24348.083607266668	75.55687711742361
2	13026.887925466668	82.91086932891363
4	6876.0444322	77.66861966519785
8	3671.4347998666663	82.15912998171454
16	2089.476156333333	75.59466282954124

OpenMP

Processos	Tempo	Limiar do intervalo de confiança
1	24558.968242	75.68246562109115
2	13275.480381666664	84.76994264756242
4	6919.889116266668	80.14724043611893
8	3700.9473324666665	83.19943715785743
16	2037.7666792000002	72.25400900993242

2 thread(s)





Pthreads

Processos	Tempo	Limiar do intervalo de confiança
1	16151.4556568	83.0896209821448
2	8527.199252466668	81.76203936024427
4	3702.7171612	69.06500455247945
8	2113.564459466667	93.30767875089816
16	1407.1128208666667	66.9709474311023

OpenMP

Processos	Tempo	Limiar do intervalo de confiança
1	14383.195559266664	85.9346591774266
2	7544.725736066668	86.41058320672417
4	3689.438994733334	81.93591883022927
8	2056.680806533333	82.6585600723781
16	1364.8364384666668	81.67521495261722

4 thread(s)





Pthreads

Processos	Tempo	Limiar do intervalo de confiança
1	15695.39265626667	105.42695854439043
2	8428.322060800001	86.65056504731804
4	2036.5857918	81.91292538976612
8	1411.9818052	59.451005295984274
16	1305.0003370000002	54.0790383332224

OpenMP

Processos	Tempo	Limiar do intervalo de confiança
1	14634.986988799998	79.22411426275279
2	7887.837378266667	76.56913448096796
4	2117.2830105333333	59.236182191075955
8	1371.4376132	64.26978463971028
16	1270.393069466667	61.67477080289395

8 thread(s)





Pthreads

Processos	Tempo	Limiar do intervalo de confiança
1	15605.376656666665	96.15638124431102
2	8367.128753666668	85.89284605066572
4	1369.5397853333336	57.522759797702
8	1306.0353913999998	54.923773443100345
16	1265.5215739999999	52.0955416944683

OpenMP

Processos	Tempo	Limiar do intervalo de confiança
1	15041.237258866668	81.98738952360316
2	8100.627470133333	88.44728505470006
4	1400.5311012666668	49.789133090714046
8	1309.0839068	62.32680979240754
16	1257.3587099333336	62.74588322499792

16 thread(s)





Pthreads

Processos	Tempo	Limiar do intervalo de confiança
1	15590.817260800004	78.71013986120725
2	8429.708035866666	85.69429238172097
4	1342.9332732666664	62.924147627474404
8	1297.9224205333335	67.22984424981455
16	1313.1147862	56.31798141071138

OpenMP

Processos	Tempo	Limiar do intervalo de confiança
1	15356.223265333334	88.59413560239219
2	8208.767922666668	99.22970072905063
4	1338.8412951333332	61.68333295993986
8	1334.6867562	58.48871595492889
16	1328.9274058	57.48578820472554

32 thread(s)





Pthreads

Processos	Tempo	Limiar do intervalo de confiança
1	15583.383464800001	73.27152111698403
2	8384.241580933332	86.70570115372348
4	1288.3229574000002	60.53769578130375
8	1298.7768172000003	62.42755760748592
16	1275.5383016	60.393118902503666

OpenMP

Processos	Tempo	Limiar do intervalo de confiança
1	15518.901824800001	98.60294762461363
2	8284.359439133334	85.89413086020737
4	1321.179723733333	65.65705660909046
8	1268.7271436666667	62.53481346305228
16	1282.2607040000003	62.60432717681288

MPI Multithreads - Discussão dos resultados

É evidente que, em geral, todos os gráficos apresentam uma redução no tempo com o aumento do número de processos, mesmo que este aumento não seja constante. Isso nos leva a crer que a paralelização usando processos e threads em conjunto pode ser uma alternativa.

Analisando o caso com 2 threads e 8 processos, não atingimos o mesmo potencial que a versão usando somente MPI com 16 processos, mesmo tendo 16 threads executando (8*2 = 16). O mesmo ocorre com 4 threads e 4 processos. Disso podemos concluir que o custo da criação dos processos somado com o custo de criação das 16 threads ultrapassa o custo de criação de somente 16 processos que ocorre na versão MPI. Entretanto, perceba que não podemos falar o mesmo para o caso de 8 threads e 2 processos.

Conforme aumenta o número de threads, é possível notar que o valor mínimo observado no tempo é alcançado cada vez mais cedo, ou seja, menos processos são necessários para atingir este valor.

É possível notar também que existe um limitante para a otimização de tempo do programa. Logo, como consequência do item anterior, após atingir esse limitante, não existe uma melhoria significativa com o aumento do número de processos.

Analisando os gráficos e considerando os custos envolvidos em comparação com os benefícios, concluimos que os valores mais adequados são 8 threads e 4 processos ou 4 threads e 8 processos. Entretanto, escolhemos como melhores parâmetros o uso de 8 threads e 4 processos, pois conseguimos ver que essa coleção de parâmetros apresenta um tempo um pouco menor, já que o custo de criação de processos é muito maior do que o de criação de threads.

Parte 2 - Comparação entre as versões

Sumário:

- Organização dos dados
- Visualização dos resultados
- Discussão dos resultados

O arquivo *comparison.csv* gerado por um dos scripts tem a estrutura apresentada abaixo.

In [99]:

```
csv = pd.read_csv("../measurements/comparison.csv")
print(csv)
```

```
       tipo  processos  threads         tempo
0       seq          1        1  24461.493969
1       seq          1        1  24884.382963
2       seq          1        1  24461.457253
3       seq          1        1  24411.528349
4       seq          1        1  24482.066631
..      ...        ...      ...           ...
85  mpi_omp          4        8   1414.837122
86  mpi_omp          4        8   1432.371378
87  mpi_omp          4        8   1666.913271
88  mpi_omp          4        8   1484.954834
89  mpi_omp          4        8   1478.092670

[90 rows x 4 columns]
```

Organização dos dados

Para agrupar os dados coletados usamos a estrutura de dados de dicionário. A estrutura pode ser entendida assim:

```
{
    seq: Pair<Média, Intervalo de confiança>,
    pth: Pair<Média, Intervalo de confiança>,
```

```
    opm: Pair<Média, Intervalo de confiança>,
    mpi: Pair<Média, Intervalo de confiança>,
    pth_mpi: Pair<Média, Intervalo de confiança>,
    omp_mpi: Pair<Média, Intervalo de confiança>,
}
```

Como o intervalo de confiança é simétrico em torno da média, só armazenamos os limiares.

In [100…

```
'''
Definição das estruturas de dados
'''
data = {"seq": (0,0), "pth" : (0,0), "omp" : (0,0), "mpi" : (0,0), "mpi_pth" : (0,0),
```

Assim, podemos processar as 15 medições e armazenar a média e o intervalo de confiança nas estruturas de dados:

In [101…

```
'''
Processamento dos dados
'''
tipos = ["seq", "pth", "omp", "mpi", "mpi_pth", "mpi_omp"]
for i, tipo in enumerate(tipos):
    vector = csv["tempo"][i*15:(i+1)*15]
    mean = sum(vector)/15
    pair = (mean, confidence_interval(vector, mean))
    data[tipo] = pair
```

A função auxiliar abaixo será usada para exibir os dados nas próximas seções:

In [102…

```
def data_print(data, types):
    print ("{:^35} {:^20} {:^30}".format("Tipo", "Tempo" , "Limiar do intervalo de co

    for idx, value in enumerate(data):
        mean, confidence_interval = data[value]
        print ("{:^35} {:^20} {:^30}".format(types[idx], mean, confidence_interval))
```

Visualização dos resultados

Para visualizar os resultados, plotamos um gráfico de barra comparando as diferentes versões.

Por motivos de melhor visualização dos resultados, optamos por exibir o eixo y em escala logarítimica com base 2.

In [103…

```
colors = ['#034f81', '#ff7f0e', '#2ca02c', '#d62728', '#9467bd', '#8c564b']

xlabels = ['Seq', 'Pthreads \n 32 threads',
           'OMP \n 32 threads', 'MPI \n 16 processos',
           'MPI_Pthreads \n 4 processos \n 8 threads', 'MPI_OMP \n 4 processos \n 8 th
```

In [104…

```
'''
Coleta dos dados para o plot de cada tipo de versão
'''
y = []
confidence_interval = []
for tipo in tipos:
    y.append(data[tipo][0])
    confidence_interval.append(data[tipo][1])
```

In [105…

```
'''
Plote dos resultados
'''
```

```python
plt.figure(figsize=(10, 8), dpi=80)
plt.bar(range(len(tipos)), y, align='center', yerr=confidence_interval, color=colors,
plt.grid(color='black', linewidth=0.5, axis = 'y')
plt.xticks(range(len(xlabels)), xlabels)
plt.yscale("log", base = 2)

plt.ylabel('tempo(ms)')
plt.xlabel('Versão')
plt.title('Comparação entre as versões usando os parâmetros determinados')
plt.show()

labels = ['Seq', 'Pthreads 32 threads',
          'OMP 32 threads', 'MPI 16 processos',
          'MPI_Pthreads 4 processos 8 threads', 'MPI_OMP 4 processos 8 threads']

'''
Print dos valores
'''
data_print(data, labels)
```

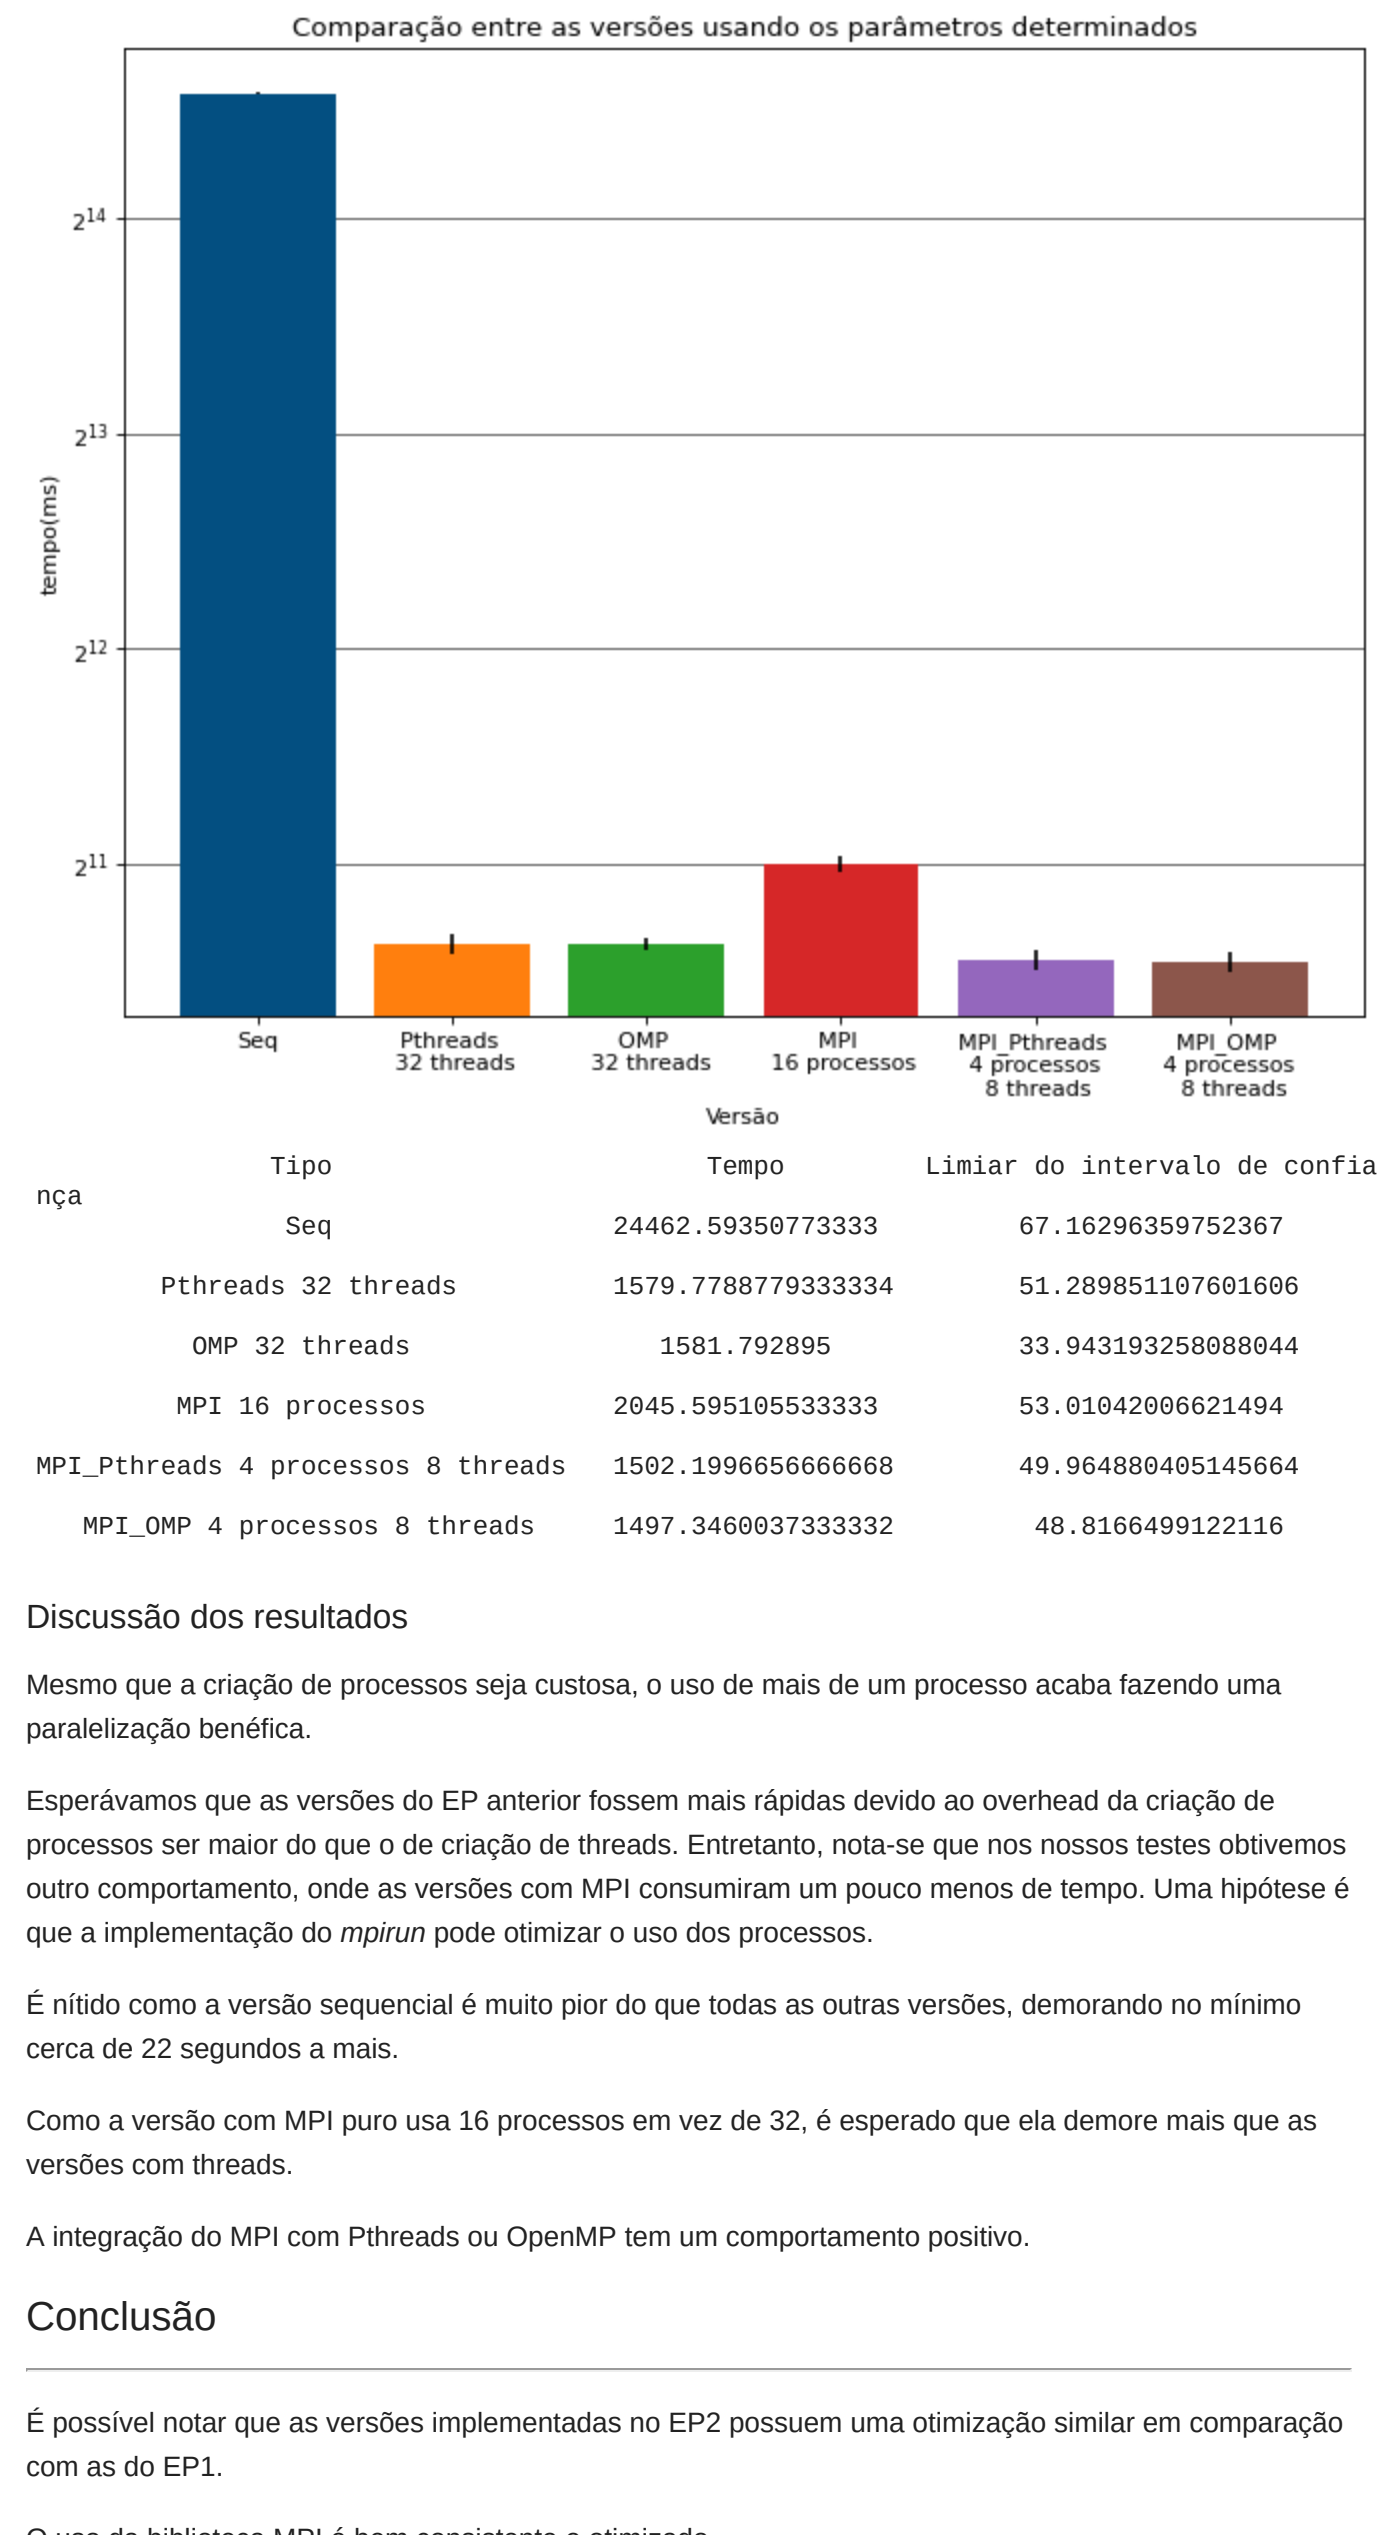

Tipo	Tempo	Limiar do intervalo de confiança
Seq	24462.59350773333	67.16296359752367
Pthreads 32 threads	1579.7788779333334	51.289851107601606
OMP 32 threads	1581.792895	33.943193258088044
MPI 16 processos	2045.595105533333	53.01042006621494
MPI_Pthreads 4 processos 8 threads	1502.1996656666668	49.964880405145664
MPI_OMP 4 processos 8 threads	1497.3460037333332	48.8166499122116

Discussão dos resultados

Mesmo que a criação de processos seja custosa, o uso de mais de um processo acaba fazendo uma paralelização benéfica.

Esperávamos que as versões do EP anterior fossem mais rápidas devido ao overhead da criação de processos ser maior do que o de criação de threads. Entretanto, nota-se que nos nossos testes obtivemos outro comportamento, onde as versões com MPI consumiram um pouco menos de tempo. Uma hipótese é que a implementação do *mpirun* pode otimizar o uso dos processos.

É nítido como a versão sequencial é muito pior do que todas as outras versões, demorando no mínimo cerca de 22 segundos a mais.

Como a versão com MPI puro usa 16 processos em vez de 32, é esperado que ela demore mais que as versões com threads.

A integração do MPI com Pthreads ou OpenMP tem um comportamento positivo.

Conclusão

É possível notar que as versões implementadas no EP2 possuem uma otimização similar em comparação com as do EP1.

O uso da biblioteca MPI é bem consistente e otimizado.

O uso em conjunto do MPI com as threads possui uma boa integração, levando a crer que o seu uso em uma rede de computadores será eficiente.

Embora os resultados possam ter sido positivos, não podemos afirmar que o MPI com threads é a melhor versão, precisaríamos de mais testes. Além disso, é sempre importante considerar que o overhead de criação de processos é significante.

O uso de processos independentes de forma eficiente promove escalabilidade do processamento em rede, o que não era possível somente com o uso de threads.